In [1]:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import datetime
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import roc_auc_score,f1_score,confusion_matrix,precision_re
call_curve
```

In [2]:

```
def date_parser_func(date):
    return datetime.datetime.strptime(date, "%Y-%m-%d %H:%M:%S")
```

In [3]:

```
df_game_result = pd.read_csv("game_results.csv",parse_dates=["timestamp"],date_p
arser=date_parser_func)
df_users = pd.read_csv("users.csv",parse_dates=["create_time"],date_parser=date_
parser_func)
df_predictions = pd.read_csv("predictions.csv")
```

In [4]:

```
df_game_result.shape
```

Out[4]:

```
(812733, 9)
```

In [5]:

```
df_game_result.head()
```

Out[5]:

	id	user_id	timestamp	winner	length	magic_used	player_cards	round	type
0	218714	218490	2019-11-10 01:14:52	1	375	7	52	1	1
1	219061	218490	2019-11-10 01:23:06	1	475	3	41	2	1
2	219430	218490	2019-11-10 01:31:24	1	476	0	13	3	1
3	219689	218490	2019-11-10 01:38:43	1	329	2	52	1	1
4	219859	218492	2019-11-10 01:42:48	1	297	2	52	1	1

In [6]:

```
df_users.head()
```

Out[6]:

	id	create_time
0	218490	2019-11-10 00:57:10
1	218492	2019-11-10 01:32:13
2	218493	2019-11-10 01:43:16
3	218499	2019-11-10 03:26:18
4	218507	2019-11-10 07:02:37

In [7]:

```
df_game_result.dtypes
```

Out[7]:

```
id                          int64
user_id                     int64
timestamp       datetime64[ns]
winner                      int64
length                      int64
magic_used                  int64
player_cards                int64
round                       int64
type                        int64
dtype: object
```

In [8]:

```
df_users.dtypes
```

Out[8]:

```
id                         int64
create_time    datetime64[ns]
dtype: object
```

Дата считалась правильно

Проверим данные на наличие пропущенных значений

In [9]:

```
df_game_result.isna().sum()
```

Out[9]:

```
id              0
user_id         0
timestamp       0
winner          0
length          0
magic_used      0
player_cards    0
round           0
type            0
dtype: int64
```

In [10]:

```
df_users.isna().sum()
```

Out[10]:

```
id             0
create_time    0
dtype: int64
```

Пропущенных значений нет

Соединим 2 набора данных

In [11]:

```
df_users.rename(columns={"id":"user_id"},inplace=True)
```

In [12]:

```
result_df = df_game_result.join(df_users.set_index("user_id"),on="user_id")
```

Как мне кажется, наиболее оптимальной будет модель использующая деревья, так как она обладает наибольшей интерпретируемостью, поэтому все сгенеренные данные не нужно будет масштабировать. Данный пункт было бы разумнее описать в части про обучение модели, но мне кажется здесь тоже уместно.

Создадим новый столбец данных: разницу между временем регистрации и временем игры в секундах

In [13]:

```
result_df['diff'] = (result_df.timestamp-result_df.create_time)
```

In [14]:

```
result_df['diff'] = result_df['diff'].apply(lambda x: x.seconds)
```

Посмотрим сколько игр сыграл каждый игрок

In [15]:

```
ax = sns.distplot(result_df.user_id.value_counts())
plt.xlabel("Количество игр")
plt.title("Плотность распределения количества игр")
```

Out[15]:

```
Text(0.5, 1.0, 'Плотность распределения количества игр')
```

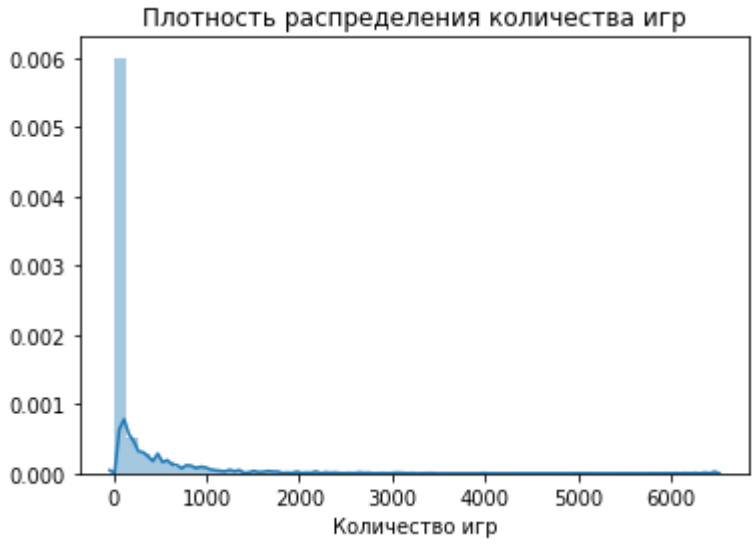

Как видно из графика распределения большинство игроков играют меньше 1000 игр, найдем это число. Найдем моду распределения.

In [16]:

```
result_df.user_id.value_counts().mode()
```

Out[16]:

```
0    3
dtype: int64
```

Большинство игроков играют 3 игры.

Рассмотрим эти данные детальнее

In [17]:

```
result_df.user_id.value_counts().describe()
```

Out[17]:

```
count    5289.000000
mean      153.664776
std       388.296857
min         1.000000
25%         3.000000
50%        12.000000
75%        95.000000
max      6479.000000
Name: user_id, dtype: float64
```

75 процентов игроков сыграли 95 или менее игр

In [19]:

```
result_df['count_of_games']=0
```

Out[19]:

	id	user_id	timestamp	winner	length	magic_used	player_cards	round	ty
0	218714	218490	2019-11-10 01:14:52	1	375	7	52	1	
1	219061	218490	2019-11-10 01:23:06	1	475	3	41	2	
2	219430	218490	2019-11-10 01:31:24	1	476	0	13	3	
3	219689	218490	2019-11-10 01:38:43	1	329	2	52	1	
4	219859	218492	2019-11-10 01:42:48	1	297	2	52	1	
...	...	...	...	...	...	...	...	...	
812728	19207349	234692	2020-05-09 11:35:10	0	254	0	9	1	
812729	19208623	234692	2020-05-09 11:50:55	0	45	0	0	1	
812730	19212265	234692	2020-05-09 12:32:59	1	701	0	16	1	
812731	19212509	234692	2020-05-09 12:36:07	1	156	0	52	2	
812732	19212820	234692	2020-05-09 12:39:57	1	199	0	52	3	

812733 rows × 12 columns

Функция для подсчета сыграных игр

In [22]:

```
def count_of_games(pd_arr):
    prev_index = -1
    for index in range(len(pd_arr)):
        if pd_arr.iloc[index]['user_id'] == pd_arr.iloc[prev_index]['user_id']:
            pd_arr.iloc[index,pd_arr.columns.get_loc('count_of_games')] = pd_arr
.iloc[prev_index]['count_of_games']+1
        prev_index = index
        if index%100000==0:
            print(index)
```

Отсортируем всех игроков по user_id и времени игры, для того, чтобы правильно посчитать количетсво сыграных игр на текущий момент

In [23]:

```
result_df.sort_values(['user_id','timestamp'],inplace=True)
```

СЛЕДУЮЩАЯ ЧАСТЬ ООЧЕНЬ ДОЛГО СЧИТАЕТСЯ

In [ ]:

```
count_of_games(result_df)
```

In [27]:

```
result_df.drop(['timestamp'],axis=1,inplace=True)
```

Вычислим день недели, возможно по выходным люди чаще становятся космонавтами

In [21]:

```
result_df = pd.read_csv("user_features.csv")
result_df['create_time'] = pd.to_datetime(result_df['create_time'], format="%Y-%m-%d %H:%M:%S")
```

In [ ]:

```

```

In [24]:

```
result_df['weekend'] = 0
```

In [25]:

```
def find_weekend(line):
    if (line['create_time'].weekday()>4):
        return 1
    else:
        return 0
```

In [26]:

```
result_df.weekend = result_df.apply(find_weekend,axis=1)
```

In [27]:

```
result_df
```

Out[27]:

	id	user_id	winner	length	magic_used	player_cards	round	type	create_ti
0	218714	218490	1	375	7	52	1	1	2019-11 00:57
1	219061	218490	1	475	3	41	2	1	2019-11 00:57
2	219430	218490	1	476	0	13	3	1	2019-11 00:57
3	219689	218490	1	329	2	52	1	1	2019-11 00:57
4	219943	218490	1	389	2	20	2	1	2019-11 00:57
...	...	...	...	...	...	...	...	...	
812728	15802664	234754	1	199	0	52	2	1	2020-04 23:10
812729	15802858	234754	1	151	0	52	3	1	2020-04 23:10
812730	15984613	234754	1	264	2	52	1	1	2020-04 23:10
812731	15984892	234754	1	129	0	52	2	1	2020-04 23:10
812732	15985250	234754	1	168	4	52	3	1	2020-04 23:10

812733 rows × 12 columns

In [28]:

```
result_df.drop(['create_time'],axis=1,inplace=True)
```

Сохраним полученные данные в файл

In [31]:

```
result_df.to_csv('user_features.csv',index=False)
```

In [5]:

```
result_df = pd.read_csv('user_features.csv')
```

In [6]:

```
result_df
```

Out[6]:

	id	user_id	winner	length	magic_used	player_cards	round	type	diff
0	218714	218490	1	375	7	52	1	1	1062.0
1	219061	218490	1	475	3	41	2	1	1556.0
2	219430	218490	1	476	0	13	3	1	2054.0
3	219689	218490	1	329	2	52	1	1	2493.0
4	219943	218490	1	389	2	20	2	1	2918.0
...	...	...	...	...	...	...	...	...	...
812728	15802664	234754	1	199	0	52	2	1	3540.0
812729	15802858	234754	1	151	0	52	3	1	3723.0
812730	15984613	234754	1	264	2	52	1	1	65639.0
812731	15984892	234754	1	129	0	52	2	1	65788.0
812732	15985250	234754	1	168	4	52	3	1	65989.0

812733 rows × 11 columns

Добавим переменную которую нужно предсказать, предварительно сохранив данные

In [7]:

```
df_pred = pd.read_csv('predictions.csv')
```

In [8]:

```
df_pred.head(3)
```

Out[8]:

	id	prediction
0	218490	0
1	218493	1
2	218499	0

In [9]:

```
result_df = result_df.join(df_pred.set_index(['id']),on='user_id')
```

In [10]:

```
result_df.corr()
```

Out[10]:

	id	user_id	winner	length	magic_used	player_cards	r
id	1.000000	0.965359	-0.012337	0.004728	-0.027301	-0.013411	-0.00
user_id	0.965359	1.000000	-0.003846	0.043626	0.000362	-0.010824	-0.00
winner	-0.012337	-0.003846	1.000000	-0.001035	0.064093	0.384497	-0.06
length	0.004728	0.043626	-0.001035	1.000000	0.152333	0.010219	-0.02
magic_used	-0.027301	0.000362	0.064093	0.152333	1.000000	0.110698	0.02
player_cards	-0.013411	-0.010824	0.384497	0.010219	0.110698	1.000000	0.00
round	-0.004061	-0.000727	-0.066190	-0.022726	0.027292	0.004712	1.00
type	-0.018008	-0.033916	-0.078429	-0.109665	-0.030518	-0.003590	-0.07
diff	0.052022	0.024627	-0.007051	-0.048775	-0.078303	-0.017428	-0.00
count_of_games	0.093812	-0.014470	-0.024228	-0.251443	-0.070643	0.026032	-0.00
weekend	-0.066613	-0.050847	0.002132	-0.013834	-0.002494	0.001688	-0.00
prediction	-0.019640	0.013601	0.010700	0.065179	0.162494	0.033252	0.00

Наибольшая корреляция предскаываемой переменной наблюдается с используемой магией и разницей во времени между играми

Пропущенные значения заполним как -1, так будет удобнее

In [11]:

```
result_df.fillna(-1,inplace=True)
```

Построение модели

Так как для предсказания будем использовать деревья, то можно не заниматься масшатибруемостью данных

Так как нужно предсказывать не по каждому матчу а по пользователю. То сгруппируем данные по "user_id"

In [22]:

```
grouped_by_user_df = result_df.groupby(["user_id"]).mean()
grouped_by_user_df
```

Out[22]:

user_id	id	winner	length	magic_used	player_cards	round	type
218490	1.412700e+06	0.729659	426.590551	0.128609	20.551181	1.784777	1.199475
218492	2.200710e+05	1.000000	316.333333	0.666667	36.000000	2.000000	1.000000
218493	2.219399e+05	0.571429	471.142857	2.285714	41.428571	1.857143	1.000000
218499	4.591860e+05	0.956522	128.391304	0.086957	25.652174	1.956522	1.000000
218507	2.285958e+05	0.750000	181.000000	2.500000	39.000000	1.750000	1.000000
...	...	...	...	...	...	...	...
234743	1.578843e+07	0.800000	196.200000	2.000000	40.000000	1.800000	1.000000
234747	1.579174e+07	1.000000	159.000000	0.666667	40.000000	2.000000	1.000000
234752	1.660011e+07	0.850000	129.473077	0.000000	26.980769	1.903846	1.561538
234753	1.579958e+07	0.666667	270.000000	0.000000	6.000000	2.000000	1.000000
234754	1.589378e+07	1.000000	205.666667	1.166667	52.000000	2.000000	1.000000

5289 rows × 11 columns

Использовать среднее не совсем хорошо, потому что оно может быть смещено, например время "diff" может быть достаточно большим, хотя человек играл только в первый день и зашел спустя пол года.

Для начала посмотрим количество объектов каждого класса

In [23]:

```
print("Количество объектов положительного класса: ",grouped_by_user_df.predictio
n[grouped_by_user_df.prediction==1].count())
print("Количество объектов отрицательного класса: ",grouped_by_user_df.predictio
n[grouped_by_user_df.prediction==0].count())
print("Их отношение: ",grouped_by_user_df.prediction[grouped_by_user_df.predicti
on==0].count()/grouped_by_user_df.prediction[grouped_by_user_df.prediction==1].c
ount())
```

```
Количество объектов положительного класса:  1159
Количество объектов отрицательного класса:  2841
Их отношение:  2.4512510785159622
```

В принципе, есть перевес одного класса, но можно попробовать и так обучить модель.

Удалим id так как после усреднения он вряд ли несет полезную информациюпосле усреднения

In [24]:

```
grouped_by_user_df.drop(["id"],inplace=True,axis=1)
```

In [48]:

```
answer = grouped_by_user_df[grouped_by_user_df.prediction==-1]
data = grouped_by_user_df[grouped_by_user_df.prediction!=-1]
```

In [49]:

```
answer.prediction.value_counts()
```

Out[49]:

```
-1    1289
Name: prediction, dtype: int64
```

In [50]:

```
answer.drop(['prediction'],axis=1,inplace=True)
```

```
/home/danilka/anaconda3/lib/python3.7/site-packages/pandas/core/fram
e.py:3997: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: https://pandas.pydata.org/pand
as-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-co
py
  errors=errors,
```

In [52]:

```
y = data.prediction.to_numpy()
X = data.drop(['prediction'],axis=1).to_numpy()
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33, random
_state=42)
```

In [53]:

```
rfc = RandomForestClassifier()
rfc.fit(X_train,y_train)
```

Out[53]:

```
RandomForestClassifier()
```

In [54]:

```
def show_results(model,X_test,y_test):
    result_proba = model.predict_proba(X_test)
    result = model.predict(X_test)
    print("ROC-AUC SCORE: ",roc_auc_score(y_test,result_proba[:,1]))
    print("F1: ",f1_score(y_test,result))
    precision,recall,treshold = precision_recall_curve(y_test,result_proba[:,1])
    sns.lineplot(y=precision,x=recall)
    plt.xlabel("Recall")
    plt.ylabel("Precision")
    plt.title("Precision Recall curve")
    print("Confusion matrix: \n",confusion_matrix(y_test,result))
```

In [55]:

```
show_results(rfc,X_test,y_test)
```

```
ROC-AUC SCORE:  0.9058921633867998
F1:  0.7659574468085106
Confusion matrix:
 [[798 133]
 [ 65 324]]
```

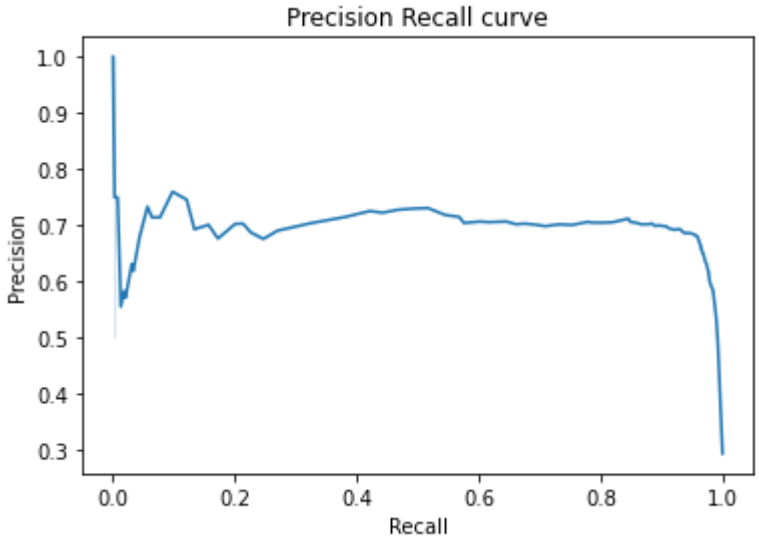

Большие значения данной метрики конечно хороши, но не могут гарантировать хорошую работу модели при дисбалансе классов, так как модели просто достаточно говорить что все поступающие объекты 0 класса, следовательно она будет права в 60 случаях из 100.

F1 метрика показывает плохие результаты, модель плохо выделяет объекты положительного класса

Впринципе можно пойти по простому пути и просто уравнять классы в объеме, так как по 6к объектов каждого из классов более чем достаточно для обучения модели (при таком количестве признаков).

Построим новую модель уже с сбалансированными классами

In [56]:

```
balanced_df = pd.concat([data[data.prediction==0][:data.prediction[data.predicti
on==1].count()],data[data.prediction==1]])
```

In [57]:

```
y = balanced_df.prediction.to_numpy()
X = balanced_df.drop(['prediction'],axis=1).to_numpy()
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33, random
_state=42,shuffle=True)
```

In [58]:

```
rfc = RandomForestClassifier()
rfc.fit(X_train,y_train)
```

Out[58]:

```
RandomForestClassifier()
```

In [59]:

```
show_results(rfc,X_test,y_test)
```

```
ROC-AUC SCORE:  0.9157408294224691
F1:  0.8837803320561941
Confusion matrix:
 [[328  66]
 [ 25 346]]
```

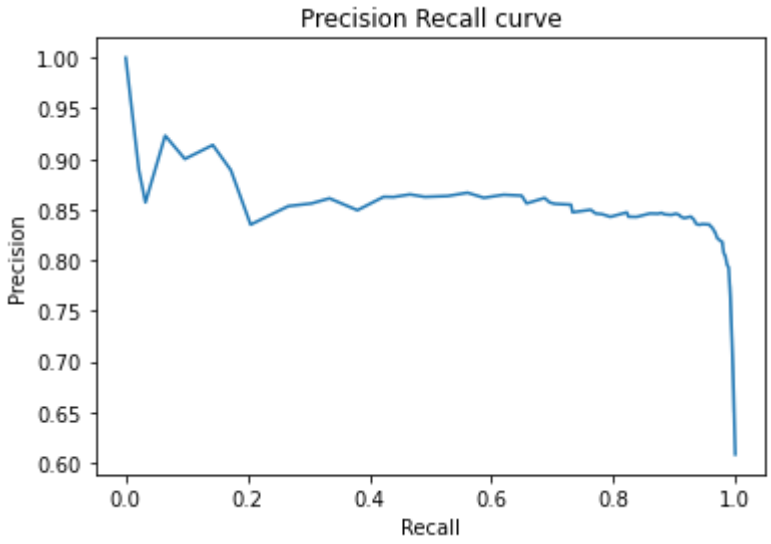

In [61]:

```
answer
```

Out[61]:

user_id	winner	length	magic_used	player_cards	round	type	diff	cou
218492	1.000000	316.333333	0.666667	36.000000	2.000000	1.0	997.666667	
218535	0.666667	193.666667	0.333333	34.666667	2.000000	1.0	686.666667	
218557	0.777778	214.888889	0.222222	31.000000	2.000000	1.0	10937.888889	
218559	0.823529	254.509804	0.209150	23.189542	1.882353	1.0	34640.254902	
218591	0.666667	199.000000	2.000000	34.666667	2.000000	1.0	747.666667	
...	...	...	...	...	...	...	...	
234715	0.500000	191.000000	0.000000	26.000000	1.500000	1.0	-1.000000	
234722	0.000000	56.000000	0.000000	0.000000	1.000000	1.0	648.000000	
234723	1.000000	517.000000	1.000000	52.000000	2.000000	1.0	-1.000000	
234734	1.000000	211.416667	0.833333	48.333333	2.000000	1.0	3495.416667	
234747	1.000000	159.000000	0.666667	40.000000	2.000000	1.0	582.333333	

1289 rows × 9 columns

Запустим модель для предсказания на неизвестных данных

In [62]:

```
result = rfc.predict(answer.to_numpy())
pd.DataFrame({"user_id":answer.index,"answer":np.int8(result)}).to_csv("Answer.csv",index=False)
```

In [63]:

```
result = rfc.predict_proba(answer.to_numpy())
pd.DataFrame({"user_id":answer.index,"answer":np.float16(result[:,1])}).to_csv("Answer_proba.csv",index=False)
```